DOCKER

Virtualisation vs conteneurs

- Virtualisation = partage de ressources physiques
- Hyperviseur :
  - Fine couche d’OS = Noyau léger
  - Alloue des ressources physiques
  - i.e instructions CPU, adresses RAM
  -

Virtualisation vs conteneurs

- Enjeux de la virtualisation
  - Meilleure adaptation aux besoins du parc informatique
  - Gain énergétique : réduction des coûts
  - Plus de flexibilité : déplacement, sauvegarde / restauration des Vms

    - PRA : Plan de Relance de l’Activité

    - RPO : « Recovery Point Objective », durée maximale d'enregistrement des données qu'il est acceptable de perdre lors d'une panne => objectif de sauvegarde

    - RTO : « recovery time objective », durée maximale d’interruption que l’on est prêt à supporter

      => objectif de restauration
  - Gain en Qualité de Service (QOS)
  - Moindres dégradations de Performances grâces au « Super - BIOS » de technos VT-x ou AMD-V

    - accès direct sur certains drivers E/S pour les os invités « para-virtualisation »

    - architectures processeur facilitant le traitements d’instructions d’un os invité étiquetées par l’hyperviseur

Virtualisation vs conteneurs

- Conteneurisation = partage des ressources logicielles du noyau de l’OS
- Logiciel de conteneurisation :
  - Créé des conteneurs
  - Isolent des processus du reste de l’OS hôte

Virtualisation vs conteneurs

- Comparaison

- Les conteneurs :
  - **Plus légers**, ne comprennent que des logiciels de haut niveau (~Mo vs ~Go pour les Vms avec leur noyau et les librairies bas niveau)
  - **Plus rapides** à créer et déplacer
- Les Vms
  - **Isolation** totale des processus entre Vms, alors que le noyau de l'hôte est partagé entre conteneurs
  - **Plus dynamiques** : Les Vms sont conçues pour les interactions utilisateur, les conteneurs pour assurer les bonnes dépendances / configuration statiques du processus à isoler

- Les usages sont différents

[redacted]inux

- Les names[redacted]
- Fonctio[redacted]ssurent certains aspects de **l'isolation** des conte[redacted]

  [redacted]ble de process par ns)

conteneurs Linux

- Les Cgroups :

Microservices

- Architecture monolithique vs microservices :
- Une application :
  -

Applications Cloud Native

- Définition :
  - Cloud Native Computing Foundation
  - Application orientée Microservice
  - Dont le cycle de vie est géré par un orchestrateur
  - **Scaling horizontal** facilité
  - Aptitude au **stockage et au calcul distribués**

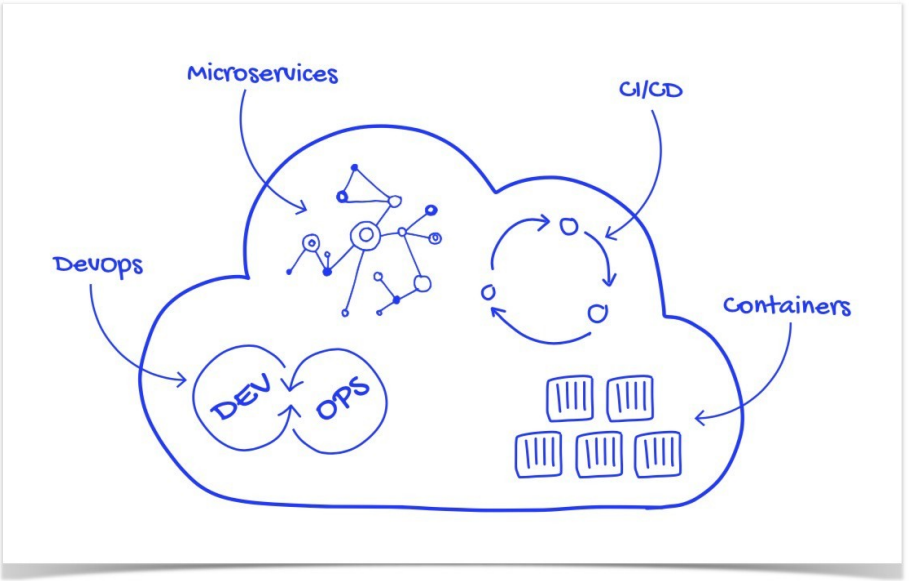

- Exemples : cncf.io
  - Kubernetes
  - Prometheus
  - Gitlab
  - ...

DOCKER

- Docker : société commerciale et technologie
- technologie :
  - Nombreuses applications prêtes l'emploi
  - Décrites par des **images** (instantanés de systèmes de fichiers)
  - Téléchargeables depuis un **registre** privé ou public (docker hub)
  - Packagées dans des conteneur**s**

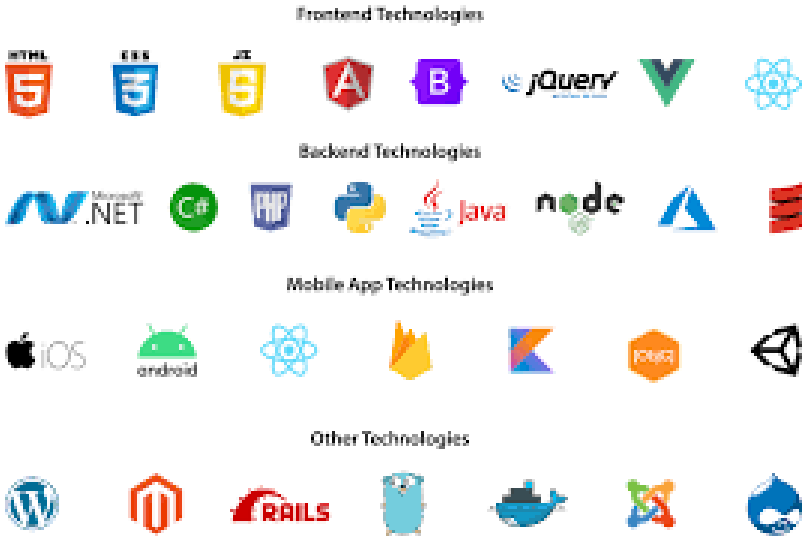

DOCKER

DOCKER

- Une technologie client-serveur:
  - Docker Cli Client
  - Dockerd : server d'API REST
  - Briques fonctionnelles
    - conteneurs
    - images de conteneurs
    - interfaces réseau
    - Volumes de données

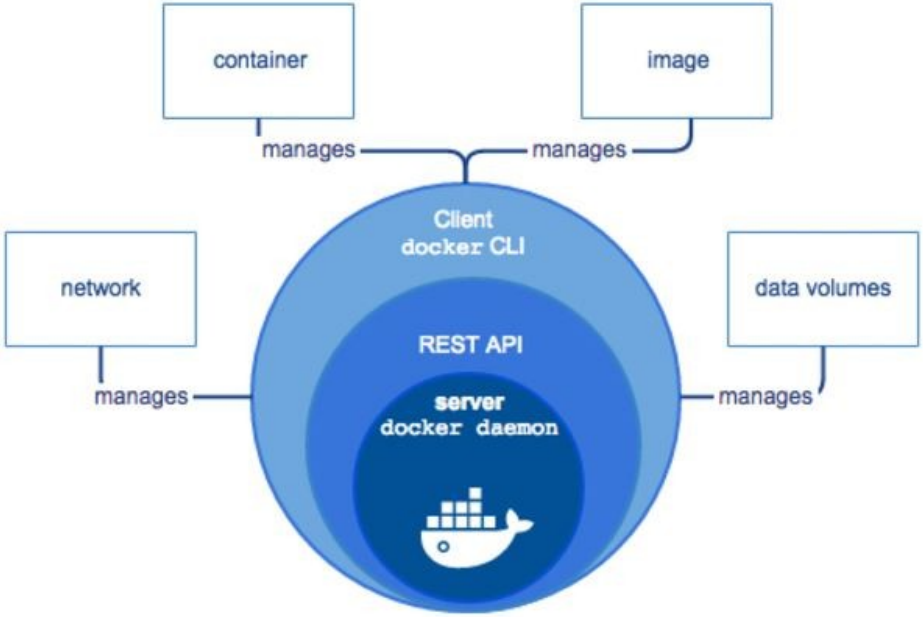

DOCKER

- Plus précisément:

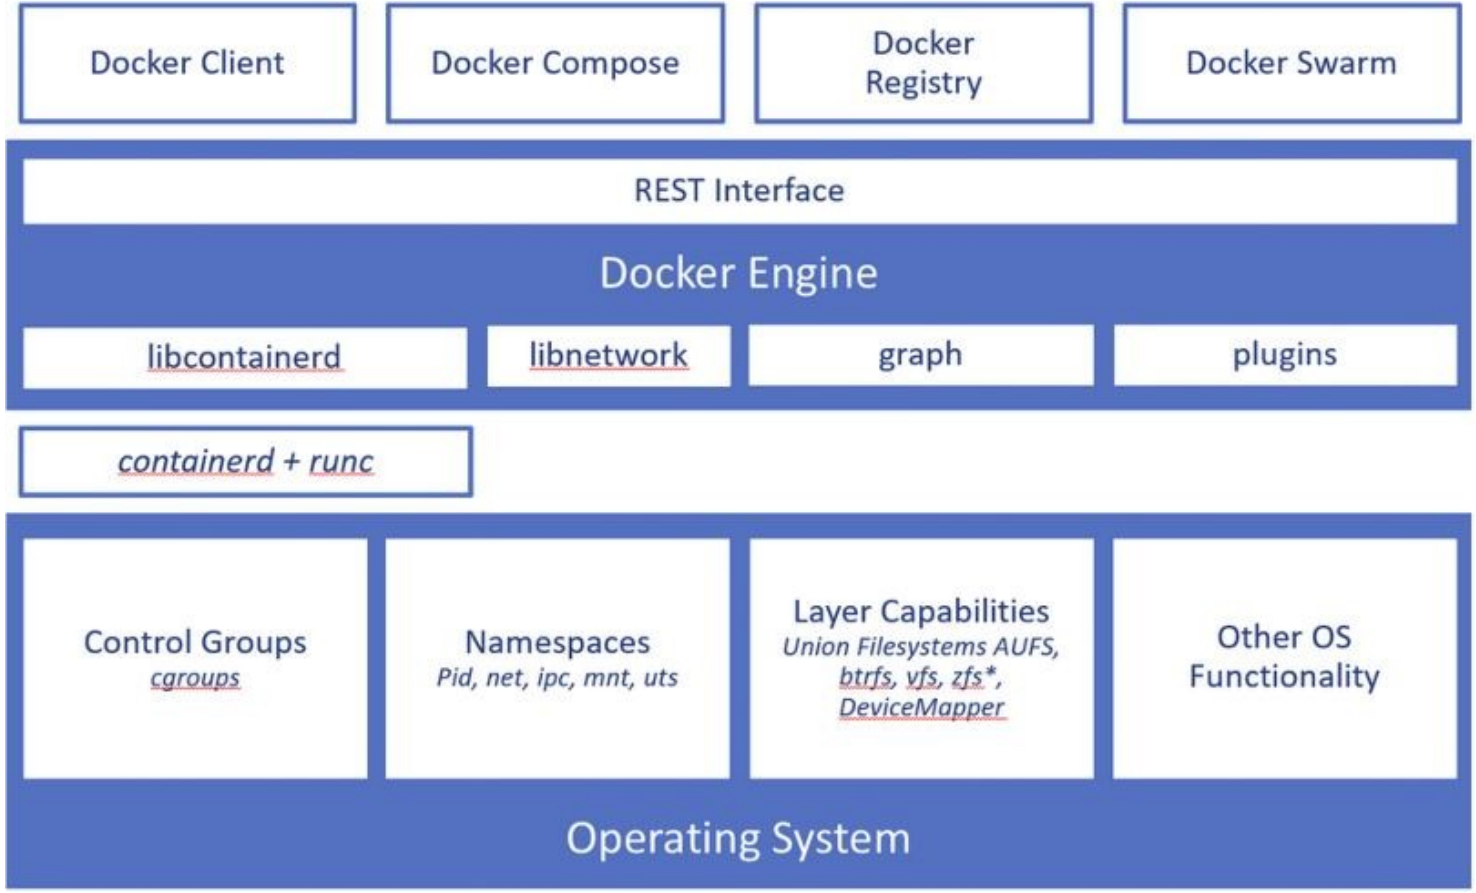

DOCKER

- responsabilités :
  - Dockerd gère
    - les call d'api et
    - le **build des images**
  - Containerd (CNCF) gère
    - les push et pull d'image (vers le **registre**)
    - le **stockage** de données
    - les couches **réseaux**
    - l'**API** de création de conteneurs
  - Runc gère
    - la manipulation de **namespaces** pour créer les conteneurs

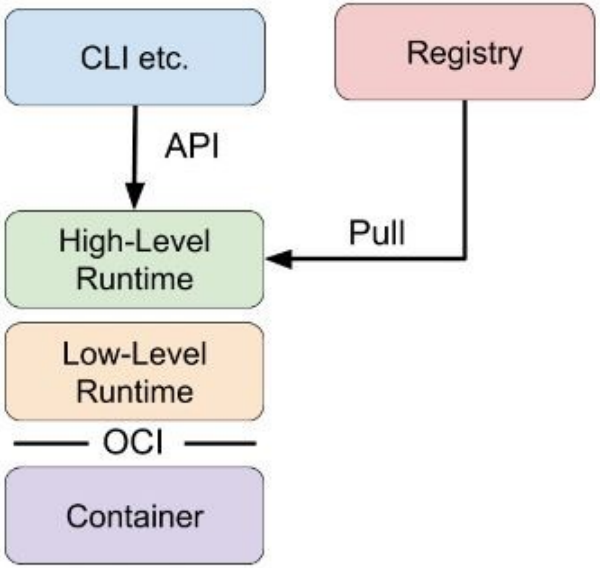

Standards pour la conteneurisation

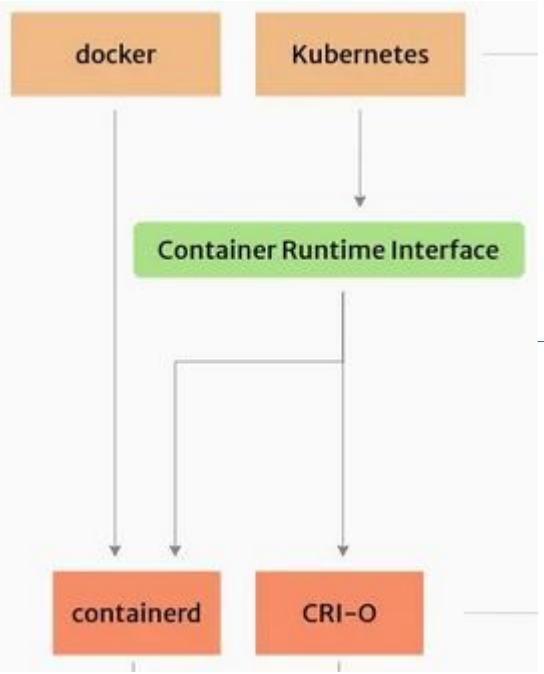

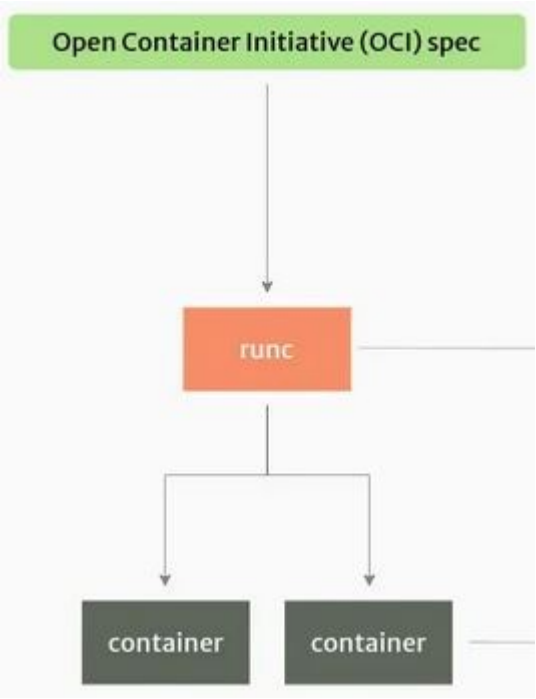

- CRI : standard pour les runtimes de Kubernetes
  Containerd est Compatible CRI

- CRI-O : runtime haut niveau de Kubernetes

- OCI : standard pour les conteneurs Linux
  Runtime bas niveau

- runc est compatible OCI

Premiers pas

- Téléchargement d'une image depuis le docker hub (hub.docker.com)
  - Une **image** décrit une technologie prête à l'emploi
  - Un **tag** précise les paquets de base et la version
  - Téléchargement : **docker pull <image>:<tag>**
  - Recherche : **docker search <image>**
  - Options courantes :
    - * --filter **key=value** (stars, is-official, is-automated)
    - * --format **"Go template : {{ .Name }}"**

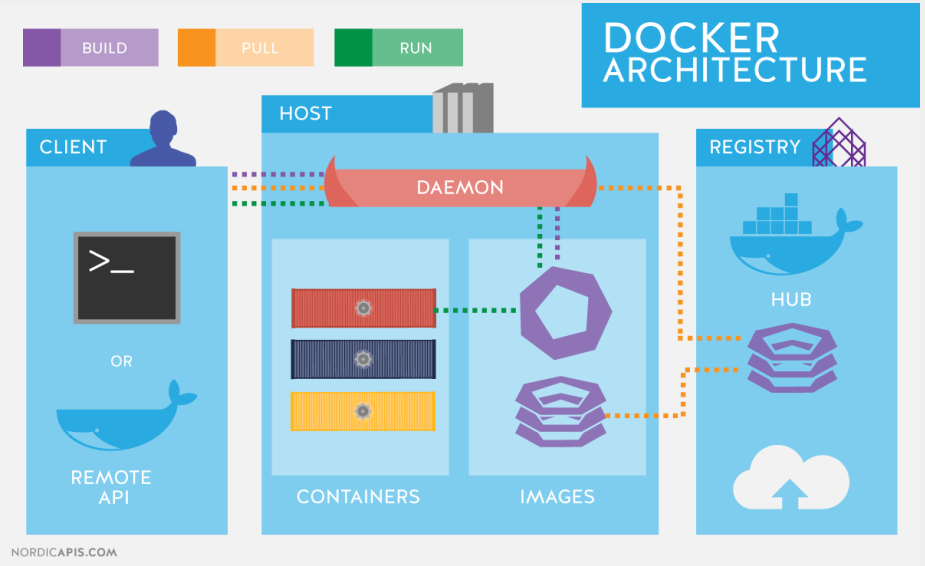

Premiers pas

- Cycle des états d'images
  - Lister : **docker image ls** ou **docker images**
  - Supprimer une image non utilisée :

    docker image rm ou **docker rmi**
  - Supprimer les images non utilisées sans tags

    docker image prune « dangling image »
  - Supprimer les images non utilisées

    docker image prune -a

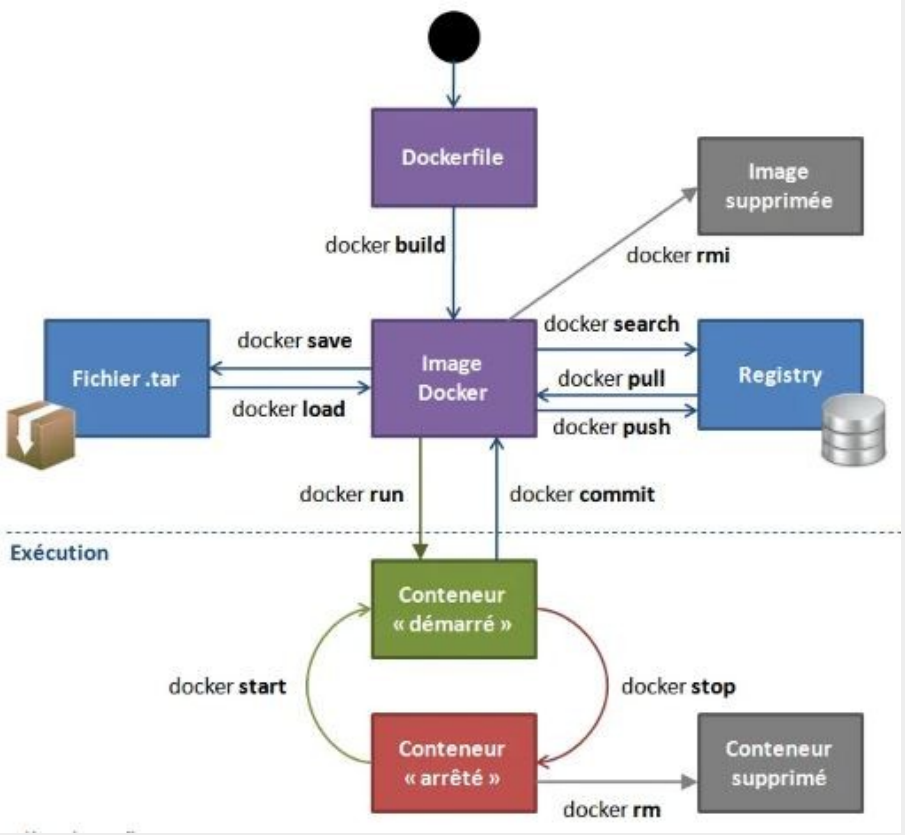

Premiers pas

- Cycle des états de conteneurs
  - Créer un conteneur : **docker create**
  - Démarrer / stopper : docker **start / stop / restart**
  - Exécuter une commande : docker **exec [cmd]**
  - **Lancer : docker run <img:tag> [cmd]**

    = create + start + exec

    - si l'image n'est pas présente, run **demande le pull**
  - Supprimer une fois stoppé : **docker rm**
  - Supprimer les conteneurs stoppés

    docker container prune [-f | --force]

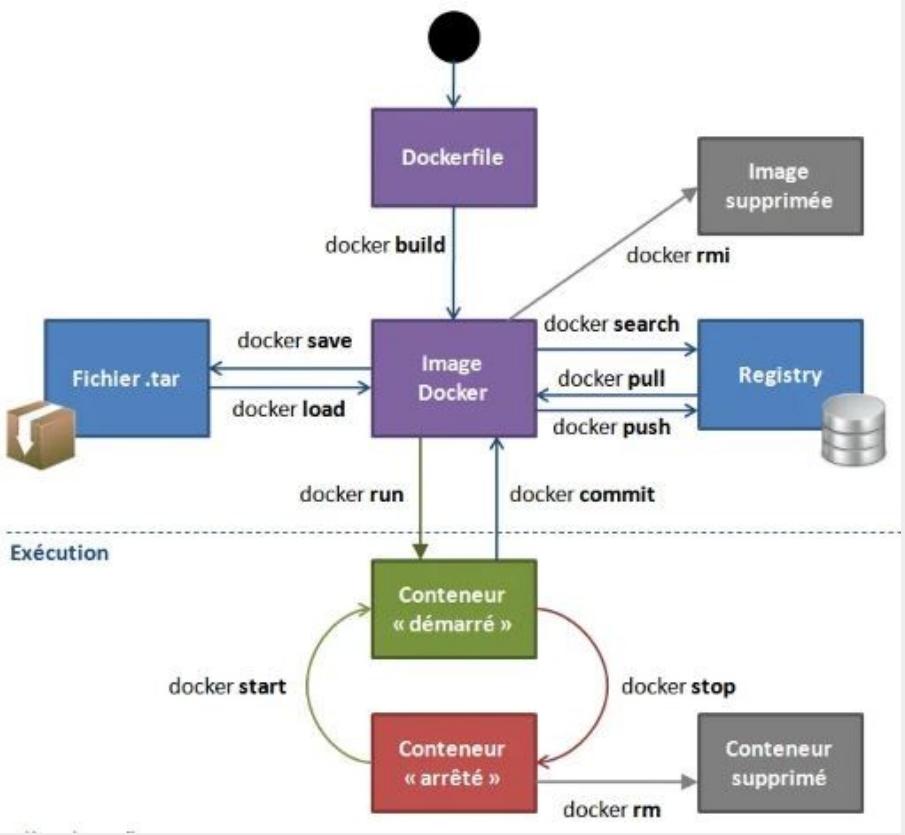

Premiers pas

- Détail du **docker run**
  - Création d'un conteneur à partir d'une image avec des **namespaces et des cgroups**

    => puis, exécution d'une commande programmée **dans l'image sous jacente**

    => le processus associé est **isolé** du reste du host par les namespaces…
  - Si le processus s'arrête normalement ou en erreur, dans tous les cas le conteneur est stoppé
  - On peut le (re)démarrer avec **docker (re)start**
  - On peut également, ajouter un autre processus dans le même conteneurs (i.e dans les namespaces)

    => avec **docker exec <ctn> <cmd>**

  - Par conséquent, un conteneur est vivant s'il contient un processus vivant :

    - un **conteneur « one shot »** exécute un processus **éphémère** qui doit modifier l'état du host d'un autre conteneur à travers le réseau ou le stockage (volumes)

    - **un conteneur « permanent »** exécute un processus de type **« daemon », un serveur** qui ne retourne pas

Premiers pas

Premiers pas

- Introspection
  - Voir la liste des conteneurs en exécution : **docker ps**
  - Voir la liste des conteneurs créés : **docker ps -a**
  - Filtrer la liste : **docker ps -f key=value** (id, name, status)
  - Liste d'identifiants (placer en entrée d'une commande): $(docker ps -a -q)

  - Afficher les informations disponibles sur un conteneur : **docker inspect**
  - Afficher seulement certaines informations : docker inspect --format **"Go template : {{ .Name }}"**

Premiers pas

- Format « GO template »
  - Technique de requêter « parser » des données,

    - en particulier les obkets json utilisés par Docker

```
# afficher un ou des champs
docker inspect --format "{{.Id}} {{.State.Status}}"

# afficher un objet ou une liste en json
        //  --format "{{json .State}}"

#       //     avec des champs séparés
        //   --format "{{join .State ' , ' }}"

# similaire à docker
(echo "ID NAME STATUS"; docker inspect $(docker
ps -q) --format '{{printf "%.10s" .Id}} {{.Name}}
{{upper .State.Status}}') | column -t -s ' '
```

Premiers pas

- Options principales d’exécution (docker run)
  - **--name** : nom du conteneur, plus compréhensible que l’id
  - **--restart** : condition de redémarrage si un erreur survient (**always**, **unless-stopped**)

Premiers pas

- Conditions d'exécution (docker run | exec)
  - **-i** : ajout d'un flux d'entrée « **stdin** » pour exécuter des commandes dans le conteneur
  - **-t** : ajout d'un driver « **pseudo-tty** » pour bénéficier des propriétés d'un terminal
  - **-it** : **Mode interactif**. Une fois lancé :
    - **Ctrl + P + Q** : revenir sur le shell de l'hôte sans interrompre le terminal conteneur, **docker attach** pour revenir
    - **exit** pour interrompre le terminal conteneur et revenir au shell de l'hôte
  - **-d** : **Mode détaché**, lancer le conteneur en arrière plan
    - sans flux d'entrées / sorties
    - le conteneur s'arrête en même temps que son processus interne
  - En mode détaché, on affiche la trace du processus du conteneur avec **docker logs**

RESEAU

- Le namespace « network » et les drivers réseau
  - Ce namespace du noyau Linux permet d'obtenir une copie logique (virtuelle) de la pile réseau de l'hôte, en la configurant spécifiquement pour un conteneur. Cela inclus :

    - l'utilisation d'interfaces réseaux, adresses et tables de routages spécifiques

    - des règles de Firewall spécifiques

  - Les drivers réseau de docker permettent de spécifier le type d'interfaces réseau à mettre à disposition des conteneurs

    - **driver bridge : par défaut**, réseau virtuel permettant à des conteneurs de communiquer entre eux sur une machine (un démon docker)

    - driver host : utilisation directe d'une interface réseau de l'hôte pour un conteneur

    - driver none : pas de couche réseau, le conteneur ne communique pas

    - **driver overlay : pour un cluster swarm** (cf infra) : agrège les réseaux associés à plusieurs démons docker (machines sur un lan ou un wan)

RESEAU

- Liaisons entre conteneur : --link pour le réseau par défaut « docker0 »
  - Pour faire communiquer plusieurs conteneurs sur docker0 on peut passer :
    - par les ips, peu pratique car on ne peut pas toujours prévoir ces ips (**--ip <ip_address>** pour une ip fixe)
    - par un alias réseau via l'option **--link <ID | Name | Name : Alias >**
  - Dans les faits, on préférera utiliser un **réseau créé par l'utilisateur** (cf infra)

```
# lien entre le conteneur courant et un conteneur ctn
docker run … --link ctn:alias
```

RESEAU

- Liaisons entre conteneurs : réseaux créés par l’ utilisateur

RESEAU

- réseaux créés par l’ utilisateur : ajouts de conteneurs
  - Création
  -

RESEAU

- Publication de ports (-p | --publish)
  - L'installation de docker comprend la création d'une interface réseau virtuelle « **docker0** » de type bridge en **172.17.0.1/16**
  - Par défaut, un conteneur est créé avec une ip allouée sur ce réseau. Les ports réseaux du conteneur ne sortent pas
  - **Publier** un port, c'est rediriger un port de l'interface docker sur une interface de l'hôte

```
# interface:port_externe:port_interne
docker run … -p 192.168.2.1:8080:80
# toutes les interfaces, choix de port, couche transport
-p 8080-8090:80/tcp
# publier tous les ports internes sur des ports > 32768
-P | --publish-all
```

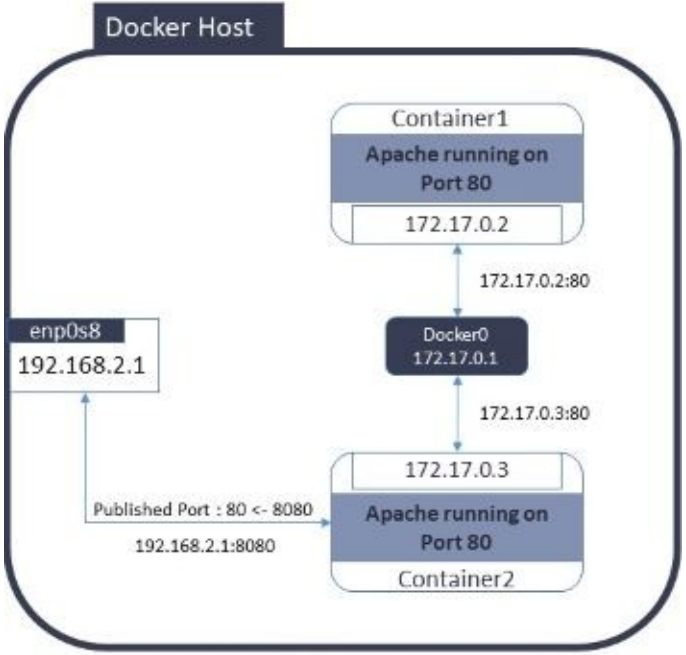

STOCKAGE

- Copier des fichiers / dossiers entre l’hôte et un conteneur

  - Sur le conteneur, le répertoire d’accueil est la racine **/**
  -

STOCKAGE

- Persistance des données dans les conteneurs
  - Toutes les données à l'intérieur d'un conteneur sont supprimées avec le conteneur
  - Les **volumes** de données permettent de partager des données entre l'hôte et les conteneurs

    - **bind mounts** : partage entre un **dossier utilisateur** et un dossier dans un ou plusieurs conteneurs

    - **volumes nommés** : partage entre un **dossier géré par docker** et un dossier dans un ou plusieurs conteneurs

    - **tmpfs** : partage temporaire enregistré en RAM, non partageable entre conteneurs
  - De fait, les données partagées existent toujours sur l'hôte

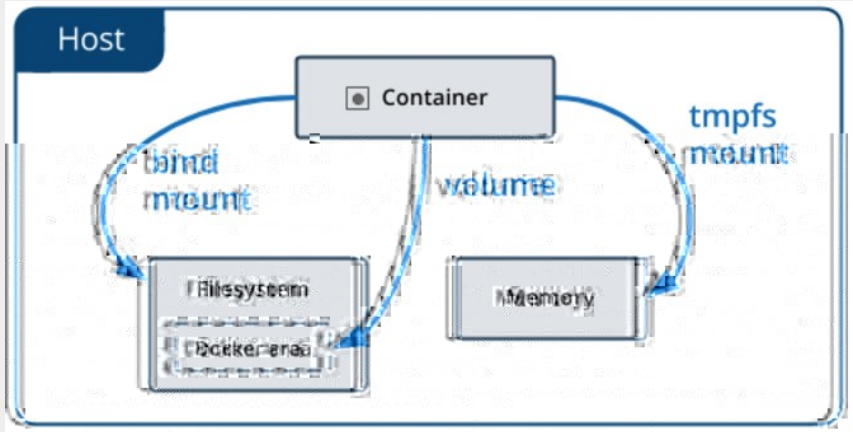

STOCKAGE

- Drivers de stockage
  - Par défaut, docker utilise le driver local **overlay2**, qui enregistre les volumes sur l'hôte en utilisant le système de fichiers **overlayFS du noyau linux > 3.18**

```
docker info
```

  - On peut spécifier d'autres systèmes de fichiers (tmpfs => RAM, sshfs => machine distante, nfs => partage NFS, CIFS => partage samba …)
  - Les volumes docker pilotent en réalité la commande linux **mount**, d'une manière ou d'une autre

STOCKAGE

[redacted]

[redacted]

STOCKAGE

- Création de volumes nommés

```
docker volume create <volume_name>
--driver local -o opt1=val1 -o opt2=val2

docker volume inspect <volume_name>
docker volume ls
```

```
# suppression de volume non lié à un conteneur en exécution
docker volume rm <volume_name> | ID

# suppression des volumes non utilisés
docker volume prune
```

DOCKER COMPOSE

- Infrastructure as Code :
  - Piloter les commandes docker
    depuis un **ficher de configuration** au format **YAML**
  - Gérer en ligne de commande plusieurs conteneurs
    comme un ensemble de services inter-connectés
    => **microservices**
  - Disponible comme plugin docker

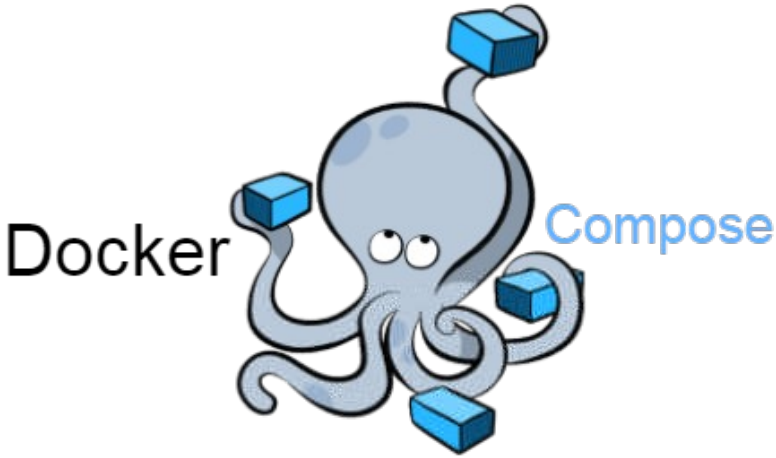


```
sudo apt-get install docker-compose-plugin
```

DOCKER COMPOSE

- Le format YAML :

Le format YAML : imbrications

- Par rapport à JSON :
  - les objets { ... } sont remplacés par une **indentation** de 2 ou 4 caractères
  - les listes [...] sont remplacés par une indentation de 2 ou 4 caractères préfixée par « **- [espace]** »
  - YAML accepte les listes et objets **JSON** comme valeur de clés

```
{                                                   ---
   "object" : {                                     object:
      "key" : "value",              =>                key: value
      "items" : [                                     items:
         "item1",                                        - item1
         { "k1": "v1", "k2": ... },                      - k1: v1
         …                                                 k2: v2
         "item3"                                         - item3
      ]
}
```

DOCKER COMPOSE

- Correspondances clé / option commandes docker (run, build, network, volume, ...)

```
services:                          # service = app conteneurisée
  app:                             # nom du service (arbitraire)
    container_name:                # --name
    image:                         # nom de l'image
    build:                         # docker build d'un Dockerfile
      context: .                   # chemin du Dockerfile
      args: [...]                  # --build-arg
    restart:                       # --restart
    depends_on:                    # dépendance à des services (qui doivent exister !)
    env_file:  [...]               # fichier de variables d'environnement
    environment:                   # variables directement dans le document
      - VAR=${PARAM:default}       # valeurs par défaut
    ports: [8080:80]               # EXT_PORT:INT_PORT ou PORT seul pour exposition
    volumes:                       #
      - type: bind                 # --mount
        source: .
        target: /
      - /src:/dev:opts             # -v
    networks: [...]                # --net
```

DOCKER COMPOSE

- Commandes docker compose principales
  - docker compose **up -d** : lancement de la stack (conteneur) dans l'ordre et en mode détaché
  - docker compose **down -v** : stopper les conteneur et les réseaux et détacher les volumes
  - docker compose **rm -f** : supprimer les conteneurs si stoppés
  - docker compose **run, exec <ctn name> <cmd>** : lancer un service standalone avec une commande
  - docker compose **logs, ps** : versions agrégées des commandes docker

DOCKER COMPOSE

- Utilisation des profiles
  - La clé **« profiles »** présente une liste d'éléments arbitraires
  - Permettent de sélectionne un série de services qui fonctionnent ensemble

- Utilisation des labels
  -

...ER DES IMAGES

...mer un conteneur en images: docker commit

CREER DES IMAGES

- Le fichier Dockerfile
  - Contient des **directives**
  - Qui modifient l'état d'une image de base
  - De multiples façon :
    - exécution de commandes
    - injection de fichiers / dossier
    - changement d'utilisateur / répertoire home
    - port réseau exposé sur l'interface docker
    - commandes à exécuter au lancement du conteneur
    - ...

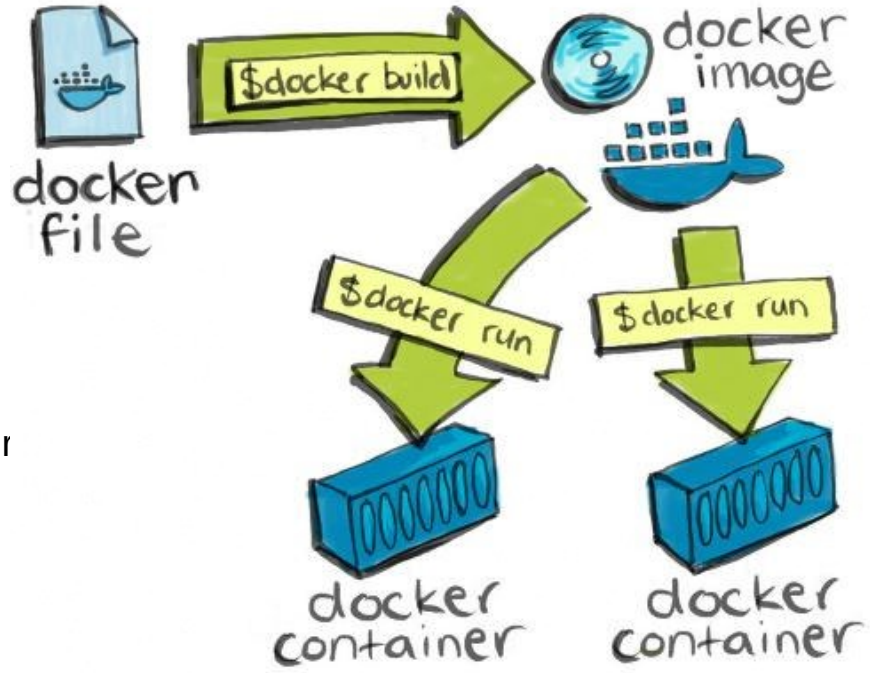

CREER DES IMAGES

- Dockerfile : principales directives
  - **FROM <image>:<tag>** : image et tag de base
  - **LABEL <key> <value>** : métadonnées de l'image (permet de filtrer les images)
  - **COPY [--option] <src> <dest>** : copie des éléments de l'hôte dans l'image
    - utilisation de wildcards (*, ?) pour les éléments source
    - possibilité de changer le propriétaire des éléments sur l'image (--chown)
  - **ADD [--option] <src> <dest>** : comme COPY mais gestion de protocoles réseaux pour la source
  - **RUN <cmd>** : exécute une commande
  - **USER <user[:group]>** : règle l'utilisateur par défaut dans l'image
  - **WORKDIR <path>** : répertoire home par défaut de l'image
  - **EXPOSE <ports>** : déclare les ports réseau sur lesquels le service installé sur l'image écoute
  - **VOLUME <paths>** : création de volumes persistant les chemins renseignés
  - **ENTRYPOINT <cmd>** : commande automatiquement lancée avec un conteneur de cette image
  -

CREER DES IMAGES

- Mécanisme du build d'image
  - Docker build créé l'image à partir du Dockerfile et du **contexte de build**
    - çàd le répertoire contenant ce dernier (en local ou dans une archive ou dans un dépôt git distant)

```
docker build -t <image : tag> path/to/context
```

  - Le fichier **.dockerignore** permet de ne pas considérer les éléments qu'il contient dans le contexte
    - éléments indisponibles pour les directives COPY et ADD
    - car le contexte est chargé côté démon docker => bande passante
  - On peut construire une image sans contexte

```
docker build -t <image : tag> - < /path/to/Dockerfile
```

CREER DES IMAGES

Paramétrer un build

- La directive **ENV** permet de déclarer ou initialiser des variables d'environnement dans l'image

```
ENV VAR
ENV VAR=default
```

- Ces variables peuvent être modifiées au lancement du conteneur

  - docker run … -e VAR=some_value

- La directive **ARG** permet de déclarer des variables initialisées au moment du build

```
ARG PARAM
...
docker build -t <image : tag> --build-arg PARAM=val
```

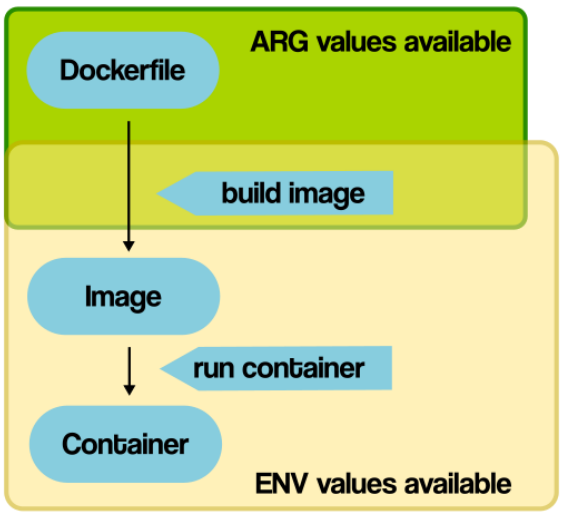

CREER DES IMAGES

- Tester un build
  - La directive **HEALTHCHECK** permet d’exécuter une commande au moment du docker run
  - Cette commande doit **démontrer** que le service dans le conteneur s’est lancé convenablement

CREER DES IMAGES

- Le « multistaging » build
  - On peut utilise plusieurs **Directives FROM** comme des étapes de construction ou **stage**
  - On peut travailler dans cette(s) image(s) auxilliaire(s) (RUN, COPY, ADD, ….)

CREER DES IMAGES

■

CREER DES IMAGES

- Mécanisme « Copy on Write » CoW d'overlayFS
  - stratégie de partage et de copie de fichiers pour une efficacité maximale.
  - Si un élément existant dans une couche inférieure de l'image est utilisé **en lecture** par une autre couche (y compris la couche conteneur) doit y accéder en lecture, **il n'est pas copié**.
  - Le même élément, **modifié** par une autre couche est **copié** sur cette couche et utilisé par les autres couches depuis cette nouvelle couche

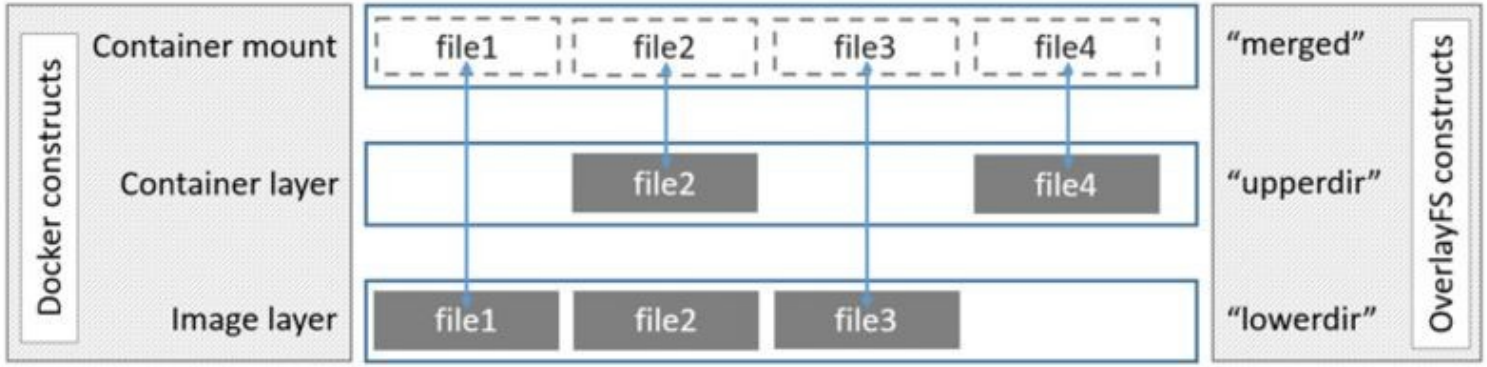

CREER DES IMAGES

CGROUPS

- Définition
  -

CGROUPS

- Limiter l’accès aux cpus (docker run)
  - **--cpus** : valeur nominale à rapporter au nb total de CPUs disponibles
    - ex : --cpus=’1.5’, pour 2 cpus ⇒ 75 %
  - **--cpuset-cpus : sélection de CPUs autorisés pour le conteneur**
    - **numérotés à partir de 0 : --cpuset-cpus=0,3**
    - sélectionner une gamme : **--cpuset-cpus=0-3**
  - On peut accéder à ces métriques via l’utilitaire **htop** lancé sur l’hôte

CGROUPS

CGROUPS

- Tester les Limites
  - Utiliser l’image **polinux/stress**
  - **docker exec -it <ID> stress -h**
  - **https://hub.docker.com/r/polinux/stress-ng**

SECURITE DES CONTENEURS

Le namespace User

- Même si l'on ajoute l'utilisateur non root dans le **groupe docker** pour utiliser la cli sans sudo,

  => les conteneurs (processus) sont créés avec root.
- Pour utiliser le démon doker (dokerd) sans être root , on doit appliquer une procédure avancée

  => **le mode ROOTLESS**
- Dans tous les cas, à la création d'un conteneur, un **namespace user** est créé

  => qui va donner l'impression au processus d'être lancé en tant que root (uid = 0)
- On peut voir le mapping de l'utilisateur dans le conteneur dans le fichier **/proc/[PID]/uid_map**

[uid dans le ctn] 0 --------- [uid dans le host] 0 ---------- [nb de mappings possibles]

- Le uid 0 dans le conteneur peut **outrepasser les permissions et les propriétés** des fichiers,

  => Mais même dans le cas 0 => 0, le root à l'intérieur n'a pas **les mêmes capacités**

SECURITE DES CONTENEURS

Les Capacités Linux

- Ensembles de permissions associées aux processus et / ou aux fichiers
- On peut voir la totalité des 39 capacité en Linux **ICI**
- On peut voir les 14 capacités **ICI** permises a priori dans les conteneur (en négatif les interdictions)
- On peut voir les capacités liées à un processus lancé en root dans le conteneur

  => ou la même chose lancé en root dans le host dans **/proc/[PID]/status | grep Cap**

uid 0 dans un ctn

```
CapInh: 0000000000000000
CapPrm: 00000000a80425fa
CapEff: 00000000a80425fa
```

uid 0 dans le host

```
CapInh: 0000000000000000
CapPrm: 0000003ffffffffff
CapEff: 0000003ffffffffff
```

- On peut ajouter ou enlever des capacités au processus (donc le conteneur) avec les options

  => **--cap-add** ou **--cap-drop**

SECURITE DES CONTENEURS

- Le filtre seccomp
  - Ensembles de permissions associées aux appels système en C utilisés en dans l'espace noyau
  - Il ya 380 appels système Linux
  - Docker utiliser un **profile JSON** par défaut de (des)activations d'appels associés aux **capacités**

    docker run --security-opt seccomp=/path/to/profile.json

```
{
   "names": [
      "mount",
   ],
  "action": "SCMP_ACT_ALLOW" ( OU  "SCMP_ACT_ERRNO" ) # oui ou non
     "includes": {   ( OU "excludes" )  # si capacité activée ou non )
         "caps": [
            "CAP_SYS_ADMIN"
         ]
      }
}
```

REGISTRE DOCKER
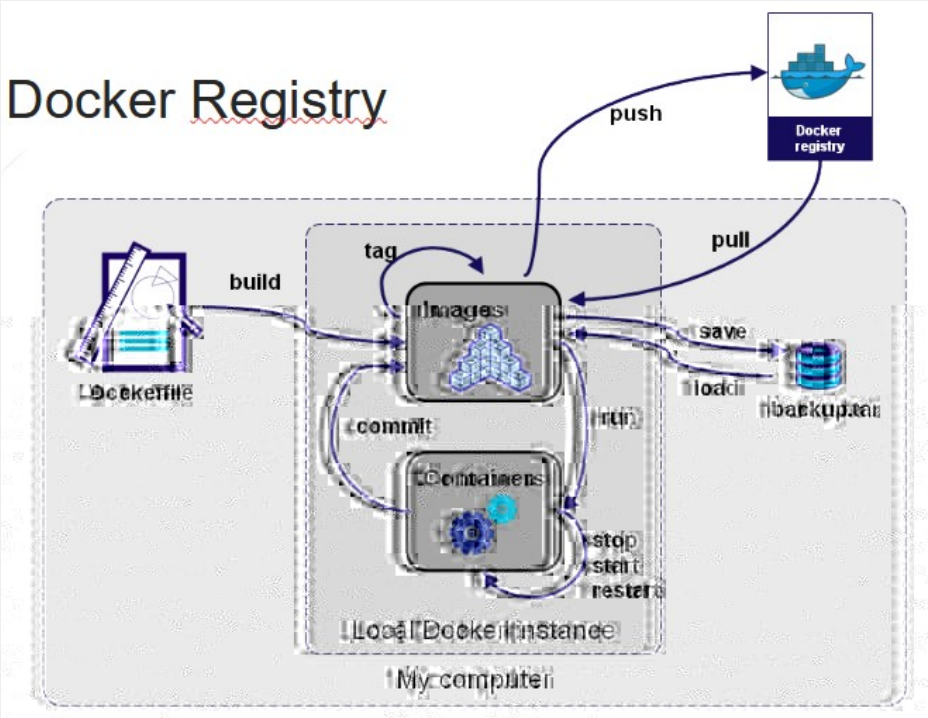
- L'image registry
  - Le dépôt public **docker hub** est installé par docker
  - Avec l'image **registry:2**
  - On peut installer son propre registre d'images privées grâce à cette image
  - Pour échanger des images avec le registre, on utilise les commandes docker suivantes
    - docker **pull**
    - docker **login -u** [uname] **-p** [passwd]
    - docker **tag** (ou docker build)
    - docker **push nom_de_domaine:port/espace_de_nom/image:tag**